

Université de Genève  
—  
Sciences Informatiques



13X005 Intelligence Artificielle  
Projet – Regression Logistique / Naive Bayes  
Repository Github: [13X005-AI-Project](#)

Gregory Sedykh, Leandre Catogni, Noah Peterschmitt, Noah Munz

Janvier 2024

# Contents

<b>1 – Introduction &amp; Rappels théoriques</b>	<b>1</b>
1.1 – Régression Logistique . . . . .	1
1.2 – Naive Bayes . . . . .	1
<b>2 – Méthodologie</b>	<b>2</b>
2.0 – Choix du dataset & outils utilisés . . . . .	2
2.1 – Gradient Descent . . . . .	3
2.2 – Régression Logistique . . . . .	4
2.2.1 – Fonction de coût pour la régression logistique . . . . .	4
2.2.2 – Apprentissage . . . . .	5
2.2.3 – Prédictions . . . . .	6
2.2.4 – Résultats . . . . .	6
2.3 – Naive Bayes . . . . .	7
<b>3 – Résultats</b>	<b>8</b>
<b>Références</b>	<b>8</b>

# Projet – Regression Logistique / Naive Bayes

## 1 – Introduction & Rappels théoriques

Dans ce document, nous approfondirons des techniques de regression logistique et “Naive Bayes” comme outils d’apprentissage supervisés.

Dans le cadre de l’intelligence artificielle et de l’apprentissage supervisé, la compréhension et la classification précises des données revêtent une importance capitale. Parmi les diverses méthodologies existantes, la Régression Logistique et “Naive Bayes” se distinguent par leur efficacité et leur applicabilité dans de nombreux contextes. Ce document se propose d’étudier ces deux techniques, en mettant l’accent sur leur mise en œuvre pratique, et leur efficacité comparative dans divers scénarios.

### 1.1 – Régression Logistique

En statistiques, la régression logistique, s’inscrit dans le cadre des modèles de régression pour les variables binaires. Bien qu’elle soit quasiment exclusivement utilisée en tant que méthode de classification.

En effet, c’est l’ajout d’un seuil, à la probabilité continue donnée par le model de regression qui nous permet de l’utiliser pour la classification.

Ce type de modèle vise à expliquer de manière optimale une variable binaire, qui représente la présence ou l’absence d’une caractéristique spécifique, à l’aide d’un ensemble conséquent de données réelles et d’un modèle mathématique.

Autrement dit, il s’agit de relier une variable aléatoire de Bernoulli, généralement notée  $y$ , aussi appelé “label” à un vecteur constitué de plusieurs variables aléatoires,  $(x_1, \dots, x_K)$ , aussi appelés “features”. [4].

La régression logistique s’appuie sur un classifieur linéaire [2] i.e. un classifieur dont la sortie (pour un vecteur de feature  $x \in \mathbb{R}^n$ ) est donnée par:

$$g(x) = f(\langle w, x \rangle + b)$$

où  $w \in \mathbb{R}^n$  est le vecteur de poids,  $b \in \mathbb{R}$  le biais et  $\langle \cdot, \cdot \rangle$  le produit scalaire usuel.  $f$  est une fonction dite de seuillage qui va séparer nos résultats. Un choix commun pour  $f$  est la sigmoïde ou la fonction signe [2].

Par exemple, dans le cas de la regression logistique binaire, on suppose le modèle suivant:

$$y_i \sim \text{Bernoulli}(p_i), \quad p_i = \sigma(\langle w, x_i \rangle + b), \quad \sigma(z) = \frac{1}{1 + e^{-z}}$$

où  $x_i$  représente un vecteur (ligne) de  $K$  valeurs pour les  $K$  features (aussi appelé un *sample*), et  $y_i$  la variable aléatoire qui représente le label qui leur est associé.

Cependant, dans notre dataset (voir [section 2.0](#)) nous avons 3 classes (3 espèces d’iris),  $y$  ne suit donc, évidemment, plus une loi de Bernoulli.

La sigmoïde étant continue, nous avons simplement modifié la manière dont nous lui appliquons le seuillage, pour distinguer 3 cas au lieu de 2. i.e. Au lieu de séparer le domaine en 2 ( $\sigma(z) \leq 0.5$ ,  $\sigma(z) > 0.5$ ), nous l’avons séparé en  $N$  (ici  $N = 3$ ). On a donc que  $y_i = k \Leftrightarrow \frac{k}{N} \leq \sigma(z) < \frac{k+1}{N}$ , ce qui a donné des résultats plus que satisfaisants comme nous le verrons en [section 2.2](#).

### 1.2 – Naive Bayes

“Naive Bayes” se présente comme une méthode de classification probabiliste basée sur le [théorème de Bayes](#), caractérisée par l’adoption d’une hypothèse d’indépendance forte entre les features (attributs), qualifiée de “naïve”.

Plus simplement, le classifieur est classifié de “naïf” car il part du principe que chaque feature (attribut) est indépendante des autres et a un poids égal quant à la probabilité qu’un point appartienne à une classe.

Ce model est dit génératif contrairement à la regression logistique étant considéré comme “méthode discriminante” [2] et consiste à modéliser les probabilités conditionnelles  $P(X|\text{classe})$  pour chaque classe  $y$  et vecteur de features  $X$  afin de trouver celle qui maximise cette probabilité.



En d'autres termes, le problème revient à trouver, pour des attributs  $X_1, \dots, X_k$ , la classe  $\tilde{y}$  telle que:

$$\tilde{y} = \arg \max_{Y \in \mathcal{Y}} \left[ P(Y) \prod_{k=1}^K P(X_k|Y) \right]$$

Citation Test: [1]

## 2 – Méthodologie

### 2.0 – Choix du dataset & outils utilisés


Pour la suite de ce projet les outils suivants ont été utilisés dans chaque parties:

- [python](#)
- [numpy](#)
- [pandas](#)
- [sklearn](#)
- [matplotlib](#)
- [ucmlrepo](#)
- [pytest](#)

Le package [ucmlrepo](#) a été utilisé pour charger les données de notre dataset depuis la base de donnée du [UC Irvine Machine Learning Repository](#).

Le dataset que nous avons choisi est le fameux dataset “Iris” [3], un des plus anciens et connus dataset de classification. Il contient 150 observations de 3 espèces différentes d’iris (Iris setosa, Iris virginica et Iris versicolor) avec  $K = 4$  features (longueur et largeur des sépales et pétales).

Voici un aperçu des points-clés du dataset:



# Iris

Donated on 6/30/1988

A small classic dataset from Fisher, 1936. One of the earliest known datasets used for evaluating classification methods.

### Dataset Characteristics

Tabular

### Subject Area

Biology

### Associated Tasks

Classification

## Variables Table

Variable Name	Role	Type	Demographic	Description	Units
sepal length	Feature	Continuous			cm
sepal width	Feature	Continuous			cm
petal length	Feature	Continuous			cm
petal width	Feature	Continuous			cm
class	Target	Categorical		class of iris plant: Iris Setosa, Iris Versicolour, or Iris Virginica	

Figure 1: Iris descriptive table

Le label que nous allons prédire sera donc *class*, i.e. l’espèce de l’iris.

## 2.1 – Gradient Descent

Dans cette section, une implémentation de la “descente en gradient” a été réalisée. La fonction a la signature suivante

```
1 def gradient_descent(df, params: NDArray, alpha: float, num_iters: int) -> NDArray:
```

Elle calcule de manière itérative le(s) paramètre(s) `params` qui minimisent la fonction dont `df` est le gradient avec un “taux de convergence” `alpha`.

La fonction a été testé avec la fonction `scipy.optimize.fmin` [5] de la librairie `scipy` sur la fonction suivante:

$$f(x) = x \cdot \cos(\pi(x + 1))$$

avec différents  $x_0 \in \{-\pi, 0, \pi\}$  (valeur initiale de `params`, i.e. `NDArray` avec `D=0`).

Les minimas locaux trouvés par les deux fonctions sont les suivants:




Figure 2: minimas locaux\_gradient descent

Ce résultat illustre bien 2 choses: la première est que l’implémentation de la descente en gradient fonctionne correctement puisque pour chaque points trouvé par notre fonction est confondu avec celui trouvé par la fonction de scipy (c’est ce qui donne cette teinte “grise”). La deuxième est que la “qualité” du minima local (i.e. la distance avec le minima globale) dépend fortement de la valeur initiale et ce pour les deux fonctions.

## 2.2 – Régression Logistique

### 2.2.1 – Fonction de coût pour la régression logistique

#### MSE – Une mauvaise idée :

Afin d'entraîner les paramètres de la régression logistique, il faut pouvoir comparer les résultats obtenus par la régression avec les résultats attendus.

Pour cela, on pourrait penser utiliser quelque chose comme la **Mean Squared Error (MSE)**, qui est une moyenne du carré de la différence entre le résultat obtenu par la régression (donné par  $z$ ) et la valeur estimée  $y$ .

La MSE nous donne une estimation de l'erreur moyenne faite entre la fonction approximative  $f$  et la valeur attendue  $y$ .

L'objectif est donc de minimiser la MSE afin de minimiser l'erreur entre les valeurs estimées et les valeurs attendues.

Ce qui nous donnerait

$$MSE = \frac{1}{n} \sum_i^n (\sigma(z_i) - y_i)^2$$

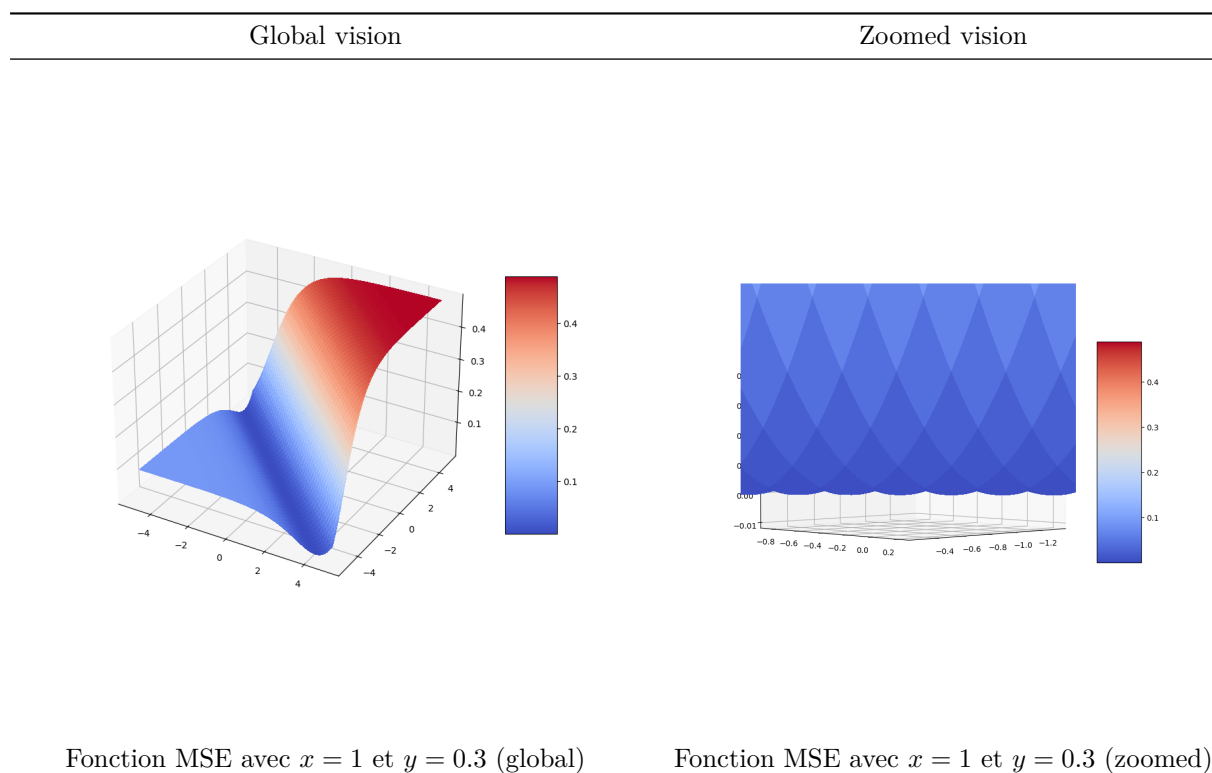
avec  $\sigma$  la fonction sigmoïde utilisée pour la régression logistique, définie comme en section 1.1 notre MSE nous donnerait:

$$MSE = \frac{1}{n} \sum_i^n \left( \frac{1}{1 + e^{-z_i}} - y_i \right)^2$$

Afin de visualiser la MSE obtenue, nous avons créé un graph de la fonction

$$MSE(w, b) = \frac{1}{n} \left( \frac{1}{1 + e^{w^T x + b}} - y_i \right)^2$$

pour  $x = 1$  et  $y = 0.3$ . Nous obtenons alors les graphes suivants:



Nous pouvons remarquer sur la figure zoomé, que la fonction admet plusieurs minimum locaux. La fonction MSE n'est donc pas convexe. Ceci est problématique pour la descente en gradient, car celle-ci risquera de se retrouver coincé dans un minimum local et ne trouvera jamais le minimum global.

Si on pouvait faire des plots pour la fonction avec plus de paramètres, on verrait mieux et plus de minimum locaux.

Cela est dû au fait que la fonction  $\sigma(z)$  n'est pas linéaire. (Découle trivialement du fait qu'il y ait une exponentielle dans la fonction.) Ce qui empêche la MSE d'être convexe.

La descente en gradient ne pourra donc pas fonctionner correctement, car on pourrait trouver des minimum locaux à la place du minimum global, ce qui nous empêcherait de trouver les paramètres optimaux pour la régression logistique.

### Log Loss – Cross-Entropy :

Pour résoudre ce problème, on utilise plutôt la **log loss** fonction, appelée également **cross-entropy**.

La formule de la log loss function est donnée par:

$$C(w, b) = \frac{1}{N} \sum_{i=0}^N \log p(y_i | x_i; w, b)$$

avec  $N$  le nombre de sample,  $y_i$  la “vrai” classe associé au sample  $x_i$  et  $w, b$  le vecteur de poids et biais. Où l'on peut ensuite développer  $p(y_i | x_i; w, b)$  pour retomber sur la cross-entropy, avec  $p(x) = y$  et  $q(x) = z$

La fonction ci-dessus pénalise fortement (du moins plus que les autres cas) les fausses prédictions “confiantes” (i.e. annonce faux + haute probabilités) et son domaine d'arrivé est de 0 à  $\infty$ , un modèle parfait aurait une log-loss de 0.

Un modèle complètement incorrect aurait, quant à lui, une log loss qui tend vers  $\infty$

### 2.2.2 – Apprentissage

Maintenant que nous avons une fonction de coût permettant de quantifier (en moyenne) à quel point un set de  $N$  prédictions est correct/incorrect à un point de l'apprentissage donné. Il ne reste plus qu'à chercher les paramètres optimaux qui minimisent cette fonction de coût. Ce que l'on va réaliser à l'aide de la descente en gradient. C'est le processus d'apprentissage.

En effet, lors de l'apprentissage, on va chercher de manière itérative les  $w$  et  $b$  qui respectent les critères mentionnés ci-dessus en calculant le gradient de la fonction de coût à chaque itérations et en allant dans la direction opposé.

Concrètement cela revient à appliquer l'algorithme suivant:

---

#### Algorithm 1 gradient descent

---

```

function GRADIENTDESCENT( $f, w_0, b_0, \alpha, \text{num\_iters}$ )
     $w \leftarrow w_0$ 
     $b \leftarrow b_0$ 
    for 1 to num_iters do
         $dw, db \leftarrow \nabla f(w, b)$ 
         $w \leftarrow w - \alpha \cdot dw$ 
         $b \leftarrow b - \alpha \cdot db$ 
    end for
    return  $w, b$ 
end function

```

---

En pratique, il est plus simple de passer directement la fonction qui calcul le gradient en argument, que d'essayer de le calculer dynamiquement, c'est pourquoi la signature de notre implémentation prend un **df** en argument plutôt que la fonction de coût elle même.

Où le calcul des dérivées partielles a été défini comme ci-dessous.

Soit  $\nabla C(w, b) = (\frac{\partial C(w, b)}{\partial w}, \frac{\partial C(w, b)}{\partial b})$ , pour un sample  $x_i$  et sa classe  $y_i$ , on obtient:

$$\begin{aligned}\frac{\partial \log(y_i|x_i; w, b)}{\partial b} &= y_i - \sigma(z_i) = y_i - \sigma(w^T X_i + b) \\ \frac{\partial \log(y_i|x_i; w, b)}{\partial w_j} &= X_{ij} \cdot (y_i - \sigma(z_i)) = (y_i - \sigma(w^T X_i + b)) \cdot X_{ij}\end{aligned}$$

Or le `db` dans l'algorithme ci-dessus se réfère à la moyenne (pour tout  $i$ ) de ces valeurs (i.e. distance moyenne *classes prédites* – *"vrai" classes*).

On l'obtient donc comme suit: (la somme des dérivées est la dérivée de la somme, linéarité de la dérivée)

$$(\nabla C(w, b))_2 = \frac{1}{N} \sum_{i=1}^N \frac{\partial \log(y_i|x_i; w, b)}{\partial b} = \frac{1}{N} \sum_{i=1}^N y_i - \sigma(w^T X_i + b)$$

De même pour `dw`:

$$(\nabla C(w, b))_1 = \frac{1}{N} \sum_{i=1}^N \frac{\partial \log(y_i|x_i; w, b)}{\partial w_j} = \frac{1}{N} \sum_{i=1}^N (y_i - \sigma(w^T X_i + b)) \sum_{j=1}^K X_{ij}$$

On retrouve ainsi, le calcul effectué dans la fonction `grad` de `log_reg.py` de signature suivante:

---

```
1 def grad(X: NDArray, y: NDArray, w: NDArray, b: float) -> tuple:
```

---

Etant donné que pour le calcul du gradient il est nécessaire d'avoir une matrice de feature  $X$  et vecteur de label  $y$ , une version "modifiée" de la descente en gradient a été implémentée.

---

```
1 def grad_desc_ml(features: NDArray, labels: NDArray, df, w: NDArray, b: float, alpha: float,
  num_iters: int) -> tuple[NDArray, float]:
```

---

Cette fonction se comporte exactement de la même manière que celle décrite en [section 2.1](#). La seule différence est qu'elle passe `features` et `labels` comme `X` et `y` à la fonction `df` (dans notre cas `df` est toujours la fonction `grad`), i.e. on a `df(features, labels, w, b)` au lieu de `df(params)`.

### 2.2.3 – Prédiction

Pour la prédiction, nous avons utilisé la fonction suivante:

---

```
1 def predict_log_reg(X: NDArray, w: NDArray, b):
```

---

qui prend simplement  $\sigma(w^T X + b)$  et seuille la sortie du sigmoïde de manière à retourner un nombre entre 0 et 2 (avec les poids et biais entraînés).

### 2.2.4 – Résultats

Suite à l'apprentissage, nous avons obtenu les résultats suivants:

$$\begin{aligned}w &= [0.53452349, 0.36463584, 1.16132476, 1.08204578] \\ b &= 0.45146791\end{aligned}$$

Nous verrons juste après, le f1-score qu'à généré ces paramètres.

L'apprentissage peut être ré-effectué de manière efficace si besoin est à l'aide du jupyter notebook [training\\_test.ipynb](#) disponible sur la branche [gpu-training](#) du repository github. Le code de l'entraînement (uniquement sur cette branche) a été "porté" sur `cuda` / `gpgpu` à l'aide de la librairie `cupy`.

A noter qu'il utilise des fonctions de `sklearn` alors que nous devions les implémenter nous-mêmes, (telles que les métriques f1-score...). Ces fonctions ont bien été implémentées mais pour une raison de simplicité, elles n'ont pas été utilisées pour l'entraînement. Le code de cette branche ne fera donc pas partie du rendu mais reste publiquement accessible sur github.



## 2.3 – Naive Bayes

Dans cette section, une implémentation d'un classifieur linéaire bayésien (naive bayes) a été réalisée. La fonction de prédiction a la signature suivante:

---

```
1 # TODO
```

---

et calcule la classe qui maximise la probabilité conditionnelle définie en section [1.2](#).

Dans cette implémentation, étant données que toutes nos features sont continues, nous avons considéré que *sepal length*, *sepal width*, *petal length* et *petal width* seront représenté comme 4 variables aléatoires  $X_0, \dots, X_3$  suivant 4 lois normales normales de paramètre  $(\mu_k, \sigma_k)$ .

C'est à dire:

$$X_k \sim \mathcal{N}(\mu_k, \sigma_k) \quad k \in \llbracket 0, 3 \rrbracket$$

## 3 – Résultats

### Références

- [1] *1.1. Linear Models*. scikit-learn. URL: [https://scikit-learn/stable/modules/linear\\_model.html](https://scikit-learn/stable/modules/linear_model.html).
  - [2] *Classifieur linéaire*. In: *Wikipédia*. URL: [https://fr.wikipedia.org/w/index.php?title=Classifieur\\_lin%C3%A9aire&oldid=189518969](https://fr.wikipedia.org/w/index.php?title=Classifieur_lin%C3%A9aire&oldid=189518969) (visited on 01/05/2024).
  - [3] R. A. Fisher. *Iris*. 1936. DOI: [10.24432/C56C76](https://doi.org/10.24432/C56C76). URL: <https://archive.ics.uci.edu/dataset/53> (visited on 01/07/2024).
  - [4] *Régression logistique*. In: *Wikipédia*. URL: [https://fr.wikipedia.org/w/index.php?title=R%C3%A9gression\\_logistique&oldid=210479759](https://fr.wikipedia.org/w/index.php?title=R%C3%A9gression_logistique&oldid=210479759) (visited on 01/05/2024).
  - [5] *Scipy.Optimize.Fmin* — *SciPy v1.11.4 Manual*. URL: <https://docs.scipy.org/doc/scipy/reference/generated/scipy.optimize.fmin.html#scipy.optimize.fmin>.
- TODO: ajouter les autres références des documentations utilisées