



# INTELLIGENCE ARTIFICIELLE PROJET – EXAMEN ORAL

## REGRESSION LOGISTIQUE & NAIVE BAYES

Gregory Sedykh, Leandre Catogni,  
Noah Peterschmitt, Noah Munz, Michel Donnet

02 Fevrier 2024




# RÉGRESSION LOGISTIQUE






# RÉGRESSION LOGISTIQUE BINAIRE: PRINCIPE





# RÉGRESSION LOGISTIQUE BINAIRE: IDÉE





# RÉGRESSION LOGISTIQUE: FONCTION D'ESTIMATION

Fonction sigmoïde

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Caractéristiques:

- Comprise entre 0 et 1  $\Rightarrow$  probabilité !
- Point d'inflexion à 0.5

Idée:

- établir un seuil afin de prédire le label  $Y$



# ENTRAÎNEMENT DU MODÈLE

But:

- maximiser la probabilité  $P(Y = y|X)$  pour  $y$  la valeur d'entrainement du label.


Mais on a la descente en gradient...

⇒ transformer le problème en problème de minimisation !

⇒ Negative Logarithm Likelihood



# RÉGRESSION LOGISTIQUE MULTINOMIALE: PRINCIPE





# GÉNÉRALISATION DE LA FONCTION SIGMOÏDE EN FONCTION SOFTMAX

$$P(Y = k|X) = \frac{1}{1 + e^{-X\theta^T}} \rightarrow \frac{e^{X\theta_k^T}}{\sum_i^N e^{X\theta_i^T}}$$





# ENTRAÎNEMENT DU MODÈLE

Même principe que pour la régression logistique binaire





# NAIVE BAYES





# NAME BAYES

- Classification probabiliste conditionnelle: théorème de Bayes :  $P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)}$ 
  - Features  $X_0, \dots, X_{K-1}$ , Classes  $Y_0, \dots, Y_{C-1}$  (ici  $C = 3, K = 3$ )
- Sepal length  $\perp$  sepal width  $\perp$  petal length  $\perp$  petal width (Hypthèse d'indépendance naïve)
- Calculer la distribution empirique des features indépendemment des autres
  - $X_i$  continue  $\Rightarrow X_i \sim \mathcal{N}(\mu_i, \sigma_i)$ , i.e. pour notre colonne de data, on calcule, la moyenne et standard deviation  $\Rightarrow$  on dit que ce sont les paramètres de la loi normale qui modélise comment les données de la colonne  $i$  sont réparties
  - $X_i$  binaire  $\Rightarrow X_i \sim \mathcal{B}(p_i)$
- On calcul l'impact qu'ont les V.A. de lois inférés de la répartition de chaque colonne sur le label que l'on veut prédire.  
E.g. Comment la répartition de  $X_2$  (longueur du pétale) nous donne une information sur le type de fleur?
- Intuitivement  $\Rightarrow$  Comment la probabilité que la longueur du pétale aie une certaine valeur influe sur le type de fleur  $Y_i$ ?
- En se prenant l'information non pas donnée par la répartition de  $X_2$  mais par la répartition de tous les  $[X_{j \in [0,3]}] \Rightarrow$  on obtient le principe du classifieur bayésien. (Chaque  $X_j$  a un poids équivalent)



# NAIVE BAYES - FORMELLEMENT

- $P(\textit{cause}|\textit{effet}) = \frac{P(\textit{effet}|\textit{cause})P(\textit{cause})}{P(\textit{effet})}$
- $P(\textit{class}|\textit{donnée}) = \frac{P(\textit{donnée}|\textit{class})P(\textit{class})}{P(\textit{donnée})} = \frac{P(\mathbf{x}|y)P(y)}{P(\mathbf{x})}$
- On aimerait (intuitivement): Calculer les probabilités que notre label ait telle ou telle classe connaissant notre sample, et prendre le max  $\tilde{y}$  i.e.

$$\tilde{y} = \arg \max_{y \in \mathcal{Y}} P(y|\mathbf{x})$$

- Ici on part du principe qu'on connaît  $\mathbf{x}$   $\Rightarrow$  perd principe de la prédiction puisque ça impose le fait que l'on doit avoir déjà observé exactement ce  $\mathbf{x}$ .
- On utilise que, le  $y$  qui maximise la formule du théorème de bayes est aussi le  $y$  qui maximise  $P(\mathbf{x}|y)P(y)$ , (car  $P(y|x) \propto P(x)P(y)$ )



# NAIVE BAYES - CONCLUSION

- $\tilde{y} = \arg \max_{y \in \mathcal{Y}} P(y|\mathbf{x})$
- $P(y|x) \propto P(x)P(y)$
- Donc  $\tilde{y} = P(\mathbf{x}|y)P(y)$
- Sepal length  $\perp$  sepal width  $\perp$  petal length  $\perp$  petal width (Hypothèse d'indépendance naïve)
- $$P(\mathbf{x}|y) = P(x_1|y) \prod_{k=2}^K P(x_k|x_{k-1}, \dots, x-1, y) = P(x_1|y) \prod_{k=2}^K P(x_k|y) = \prod_{k=1}^K P(x_k|y)$$
- En on conclut donc que

$$\tilde{y} = \arg \max_{y \in \mathcal{Y}} \left[ \prod_{k=1}^K P(x_k|y) \right]$$

- On prédit la classe  $\tilde{y}$  d'un sample  $\mathbf{x}$ , en calculant le maximum de la probabilité conditionnelle  $P(\mathbf{x}|classe)$  pour chaque classe.



# EVOLUTION DES MÉTRIQUES





## CONTEXTE :

Les mesures d'évaluations permettent d'analyser les performances de prédictions d'un modèle, à l'aide d'un "test set".

### **Rappel :**

Test set : Données dont on connaît les labels exacts, que l'on cachera afin de tester les prédictions faites par le modèle.



## DÉFINITIONS UTILES :

Dans le contexte multinomial considérons un label positif et des labels négatifs (ie. ceux qui diffèrent du label positif), on a alors :

- **True positive (TP)** : Labels positifs qui ont été correctement prédits comme tel
- **False Positive (FP)** : Labels négatifs prédits comme positifs
- **True negative (TN)** : Labels négatifs prédits comme négatifs
- **False Negative (FN)** : Labels positifs prédits comme négatifs





# PRÉCISION

- **Intuition** : Proportion des prédictions positives correctes (TP) par rapport à toutes les prédictions positives (TP + FP).
- **Cas multinomial** : Moyenne des précisions pour chaque label positif possible.
- **Définition** :

$$\frac{1}{|L|} \cdot \sum_{l \in L} \frac{TP_l}{TP_l + FP_l}$$

où  $L$  est l'ensemble des labels



## RAPPEL :

- **Intuition** : Proportion des prédictions positives correctes (TP) par rapport aux positifs réels (du test set) (TP + FN).
- **Cas multinomial** : Moyenne des rappels pour chaque label positif possible.
- **Définition Formelle** :

$$\frac{1}{|L|} \cdot \sum_{l \in L} \frac{TP_l}{TP_l + FN_l}$$

où  $L$  est l'ensemble des labels



## F1 SCORE :

- **Intuition** : Combinaison de la précision et du rappel (moyenne harmonique)
- **Définition** :

$$\frac{2}{\text{rappel}^{-1} + \text{precision}^{-1}} = 2 \cdot \frac{\text{precision} \cdot \text{rappel}}{\text{precision} + \text{rappel}}$$



# ACCURACY :

- **Intuition** : Proportion des prédictions correctes parmi l'ensemble total des prédictions.
- **Définition** :

$$\frac{\text{Nombre de predictions correctes}}{\text{Nombre total de prediction}} = \frac{TP + TN}{TP + TN + FP + FN}$$



# OVERFITTING

On ne veut pas apprendre le bruit des données d'apprentissage !




# SUR-APPRENTISSAGE: EXEMPLE


Overfitting.





# SUR-APPRENTISSAGE: GRAPHIQUE









## AUTRES TECHNIQUES ?

- Ajout données d'apprentissage modifiées (pour plus de généralisation...)
- Retirer des caractéristiques
- ...




# CONCRÊTEMENT, DANS LE PROJET

Dans le projet, pour montrer le phénomène de sur-apprentissage:

- Ajout de bruits aux données d'apprentissage
- Volume réduit de données
- Modification du nombre d'itérations




# RÉSULTATS OBTENUS






# RÉSULTATS OBTENUS





# RÉSULTATS OBTENUS






# ANALYSE DES FEATURES





# ANALYSE DES FEATURES


- Pic bleu et rouge faible  
⇒  $X_0$  et  $X_1$  - ont moins  
d'influence sur la classe.
- Chevauchement faible ⇒  
peu interdépendance





# ANALYSE DES FEATURES

- pic bleu et vert faible  
⇒  $X_0$  et  $X_2$  - ont moins d'influence sur la classe.
- Chevauchement fort entre bleu et vert et vert et rouge  
⇒ interdépendance entre  $X_1$  et  $X_2$  et  $X_0$  et  $X_2$








# ANALYSE DES FEATURES

- Pic bleu et vert faible  
⇒  $X_0$  et  $X_2$  - ont moins d'influence sur la classe.
- Chevauchement fort entre bleu et vert et rouge et magenta  
⇒ interdépendance entre  $X_1$  et  $X_3$  et entre  $X_0$  et  $X_2$





## FONCTIONS UTILISÉES

`plot_util.py` : modification de la fonction `plot_vs` afin de pouvoir comparer jusqu'à 4 fonctions.

`feature_analyse_plot.py` : affichage pour chaque classe les courbes des normal PDF de chaque données.



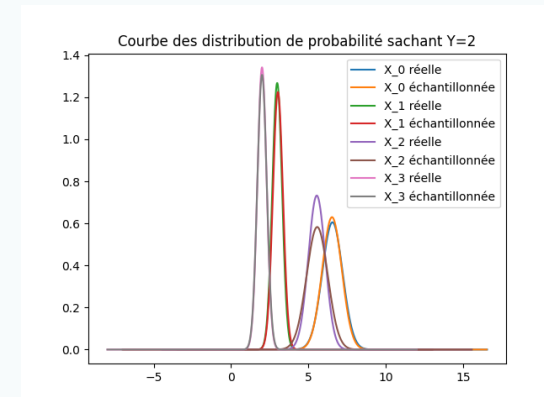
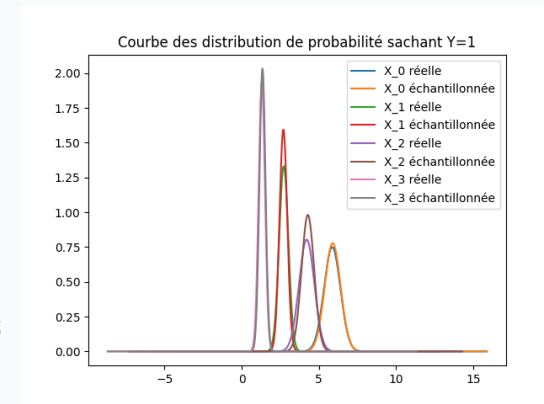

# SAMPLING






# SAMPLING

- Une fois que les paramètres des classes sont obtenus en supposant l'indépendance des variables, on échantillonne de nouvelles données afin de comparer les résultats obtenus avec les données d'origine.
- L'échantillonnage est fait dans le fichier `sampling.py`.
- On fait 50 échantillons pour chaque classe, à partir des paramètres des distributions obtenus dans la section précédente.
- On obtient les résultats suivants (la moyenne et l'écart-type sont donnés pour chaque classe et chaque variable):





## GRAPHS PAR CLASSE ( $Y \in \{0, 1, 2\}$ )





# RÉSULTATS

## COMPARAISON AVEC SKLEARN





# NAIVE BAYES

## NOTRE NAIVE BAYES

- Precision: 0.976
- Recall: 0.974
- Accuracy: 0.977
- F1 score: 0.975

## SKLEARN NAIVE BAYES

- Precision: 0.976
- Recall: 0.974
- Accuracy: 0.977
- F1 score: 0.975





# LOGISTIC REGRESSION

## NOTRE LOGISTIC REGRESSION

- Precision: 0.850
- Recall: 0.846
- Accuracy: 0.866
- F1 score: 0.848

## SKLEARN LOGISTIC REGRESSION

- Precision: 0.976
- Recall: 0.974
- Accuracy: 0.977
- F1 score: 0.975





# CONCLUSION

